Cleaning Log

Tim: Ngoding Jago
Dataset: Sales Transaction v.4a (`Sales_Transaction_v_4a.csv`)
Baris mentah: 536.350 → **baris bersih:** 531.150
Terakhir diperbarui: 19 Oktober 2026

Urutan langkah

#	Langkah	Kolom	Baris terdampak	Keputusan	Alasan
1	Perbaiki tipe data	CustomerNo	536.295	float diubah menjadi ID teks	ID tidak untuk dijumlahkan atau dirata-ratakan; float juga menampilkan ".0" (17490.0) yang menyesatkan
2	Perbaiki tipe data	Date	536.350	teks diubah menjadi datetime, format M/D/YYYY	Bulan berada di depan (contoh 4/19/2019, tidak mungkin dibaca hari-bulan). `dayfirst=True` akan menukar bulan dan hari secara diam-diam untuk tanggal 12 ke bawah. Nol

#	Langkah	Kolom	Baris terdampak	Keputusan	Alasan
					kegagalan parsing. Tidak ada kolom jam, jadi analisis per jam tidak mungkin
3	Buang spasi pada kolom teks	semua kolom teks	0	tidak ada yang perlu dibuang	Pemeriksaan tetap dijalankan dan dicatat karena spasi tersembunyi memecah `groupby`
4	Placeholder teks menjadi kosong	Country	447	"Unspecified" menjadi kosong	Bukan nama negara. Daftar placeholder standar diperluas setelah nilai unik Country diperiksa. Kolom teks lain 0 placeholder
5	Placeholder numerik menjadi kosong	Price, Quantity	0	tidak ada sentinel (-999, 9999, 99999, 999999)	Sudah diperiksa. Tipe kolom sengaja tidak diubah bila tidak ada yang diganti
6	Seragamkan kategori	Country	8.105	EIRE menjadi Ireland, RSA	Nama lokal atau

#	Langkah	Kolom	Baris terdampak	Keputusan	Alasan
				menjadi South Africa	singkatan diganti nama baku lewat peta eksplisit. Tidak ada "Ireland" lain yang bertabrakan. "European Community" sengaja tidak ditebak
7	Tangani duplikat	semua kolom	5.200	baris identik penuh dibuang, satu disimpan	Delapan kolom sama persis termasuk Quantity. Ini asumsi (ganda input), bukan fakta, jadi dicatat. Dibiarkan akan menggandakan nilai sebesar 163.265,87
8	Tangani duplikat	TransactionNo + ProductNo	11.336	ditandai `kunci_berulang`, tidak dibuang	TransactionNo adalah nomor faktur, bukan kunci baris. Pasangan (faktur, produk) berulang punya

#	Langkah	Kolom	Baris terdampak	Keputusan	Alasan
					Quantity berbeda pada 5.207 kelompok dan Price berbeda pada 1.033 kelompok. Membuang menghilangkan 5.783 baris penjualan; menjumlahkan ditolak karena harga di sebagian kelompok berbeda
9	Tangani duplikat	TransactionNo, ProductNo	0	baris tanpa kunci akan dibuang	Kunci kosong tidak bisa ditelusuri ke sumber. Hasilnya 0, kunci lengkap
10	Tangani nilai mustahil	Quantity	8.548	ditandai `is_pembatalan`, dipertahankan	Quantity negatif cocok 100% dengan faktur berawalan C, nol pengecualian. Ini retur sah. Dikosongkan ditolak (info hilang, penjualan neto salah).

#	Langkah	Kolom	Baris terdampak	Keputusan	Alasan
					Dibalik menjadi positif ditolak (menggandakan penjualan). Dibuang ditolak (retur 4,2% dari penjualan bruto ikut hilang)
11	Tangani nilai mustahil	Price	0	Price 0 atau negatif akan dikosongkan	Harga nol tidak masuk akal untuk barang yang dijual. Hasilnya 0. Harga minimum 5,13
12	Tangani nilai mustahil	Price	2.127	ditandai `harga_menyimpang`	Harga lebih dari 3 kali atau kurang dari sepertiga median produk itu. Penyebab tidak diketahui (diskon, salah input, perubahan harga), jadi ditandai, tidak ditimpa. Batas 3 kali dan sepertiga

#	Langkah	Kolom	Baris terdampak	Keputusan	Alasan
					adalah keputusan tim
13	Tangani nilai mustahil	Quantity	5	ditandai `qty_ekstrem`	Nilai mutlak di atas 10.000 (80.995, 74.215, 12.540, dan dua pembatalannya). Bisa salah ketik atau pesanan grosir. Standar deviasi Quantity turun dari 217,7 menjadi 40,7 bila lima baris ini dikeluarkan. Penanganan outlier menunggu pertemuan 6
14	Tangani nilai mustahil	Price	48.872	ditandai `harga_periode_turun` (mulai 2019-11-23)	Median harga harian runtuh dari sekitar 12 menjadi 6,19 pada satu tanggal, dan menetap sampai akhir data. Pergeseran

#	Langkah	Kolom	Baris terdampak	Keputusan	Alasan
					struktural, bukan salah input per baris. Sebab tidak diketahui, jadi tidak dikoreksi
15	Tangani nilai kosong	CustomerNo	55	dibiarkan kosong, ditandai `ada_pelanggan`	54 dari 55 baris berasal dari faktur pembatalan, padahal pembatalan hanya 1,6% data, jadi kosongnya tidak acak. ID pelanggan tidak bisa diimputasi tanpa mengarang atribusi. Modus akan menambah 55 baris ke pelanggan 17841 (7.803 menjadi 7.858)
16	Tangani nilai kosong	Country	443	dibiarkan kosong	Berasal dari "Unspecified" (443 setelah duplikat dibuang). Tidak ada kolom lain

#	Langkah	Kolom	Baris terdampak	Keputusan	Alasan
					yang dapat menentukan negara
17	Buat kolom turunan	bulan, hari, nilai_total, kelas_nilai	531.150	kolom baru ditambahkan	`nilai_total` = Price x Quantity, bertanda negatif untuk retur. `kelas_nilai` memakai batas 20, 100, 300 pada nilai mutlak, dipilih dari kuartil sebaran (kira-kira 18, 44, 119) lalu dibulatkan

Catatan: notebook mencatat langkah 1 sampai 16 secara otomatis (`jejak`). Langkah 17 ditulis di sini karena template meminta langkah kolom turunan.

Peta keputusan manual

Nilai asal	Diubah menjadi	Dasar keputusan
EIRE	Ireland	Nama lokal untuk Irlandia. Tidak ada "Ireland" lain di data, jadi tidak ada penggabungan yang menimpa. Perlu dikonfirmasi ke pemilik data

Nilai asal	Diubah menjadi	Dasar keputusan
RSA	South Africa	Singkatan Republic of South Africa
Unspecified	(kosong)	Penanda "tidak diketahui", bukan nama negara
Faktur berawalan C	`is_pembatalan = True`	Awalan C cocok 100% dengan Quantity negatif pada 8.548 baris, tanpa pengecualian
European Community	tidak diubah	Bukan negara tunggal dan tidak ada dasar untuk menebak negaranya (58 baris)

Yang sengaja TIDAK diubah

Masalah	Mengapa dibiarkan	Akibat bagi analisis
Faktur pembatalan (8.548 baris, Quantity negatif)	Retur sah. Membuang atau membalik tandanya menyalahkan penjualan neto	Penjualan bruto 62,78 juta, retur -2,66 juta, neto 60,12 juta. Analisis penjualan harus memisahkan retur dengan `is_pembatalan`
Pasangan (faktur, produk) berulang (11.336 baris)	Bukan duplikat input: Quantity dan sebagian Price berbeda	Jumlah baris tidak sama dengan jumlah produk unik per faktur. Agregasi per produk harus menjumlah Quantity
Pergeseran harga mulai 2019-11-23 (48.872 baris, 9,2% data)	Sebabnya tidak diketahui	Pendapatan Nov-Des 2019 tidak sebanding dengan bulan sebelumnya. Analisis tren perlu dijalankan dengan dan tanpa `harga_periode_turun`

Masalah	Mengapa dibiarkan	Akibat bagi analisis
Quantity ekstrem (5 baris)	Mungkin sah, berpasangan dengan pembatalan	Mean dan standar deviasi Quantity sangat dipengaruhi lima baris ini. Diputuskan di pertemuan 6
CustomerNo kosong (55 baris)	ID tidak bisa dikarang	Analisis per pelanggan mengecualikan 55 baris, hampir semuanya retur
Country kosong (443 baris) dan European Community (58 baris)	Tidak ada dasar untuk menebak	Analisis per negara mengecualikan baris kosong. 90,4% data berasal dari United Kingdom

---

Pertanyaan yang belum terjawab

- ☐ Mengapa median harga turun sekitar separuh dan menumpuk di 6,19 mulai 23 November 2019? (diskon, perubahan sistem, atau data diubah)
- ☐ Apakah 5.200 baris identik penuh adalah ganda input atau scan ganda yang sah?
- ☐ Apa arti "Unspecified" dan "European Community" pada Country?
- ☐ Mengapa CustomerNo kosong hampir seluruhnya di faktur pembatalan?
- ☐ Apa mata uang Price? Data tidak menyebutkannya
- ☐ Apakah pesanan 80.995 dan 74.215 unit (lalu dibatalkan penuh) pesanan nyata atau uji sistem?
- ☐ Asal data (nama sumber, tanggal pengambilan, lisensi) belum tercatat dari README

Dampak keseluruhan

Ukuran	Sebelum	Sesudah	Catatan
Jumlah baris	536.350	531.150	5.200 duplikat persis dibuang (0,97%)
Jumlah kolom	8	20	12 kolom penanda dan turunan ditambahkan. Kolom

Ukuran	Sebelum	Sesudah	Catatan
			asli tidak berubah nama
Total sel kosong (8 kolom asli)	55	498	Bertambah 443 karena "Unspecified" kini jujur mengaku kosong. CustomerNo tetap 55
Baris duplikat	5.200	0	
Kategori pada kolom kunci (Country)	38	37	"Unspecified" menjadi kosong. EIRE dan RSA hanya berganti nama
Nilai unik CustomerNo / ProductNo / TransactionNo	4.738 / 3.768 / 23.204	4.738 / 3.768 / 23.204	Tidak berubah karena duplikat yang dibuang ada di dalam faktur yang sama

Nilai kosong bertambah, dan itu wajar: placeholder yang menyamar sebagai nama negara kini terhitung kosong.

Reproduktibilitas

- ☑ Pembersihan dibungkus dalam satu fungsi `bersihkan()`. Dijalankan dua kali hasilnya identik, dan sama dengan langkah manual di notebook
- ☑ Hasil tersimpan di `data/processed/sales_bersih.csv`
- ☑ Data mentah tidak diubah (`mentah.copy()`), notebook hanya membaca CSV
- ☐ Notebook berjalan dari awal sampai akhir setelah *Restart and run all* di Colab (sudah diuji di lingkungan lokal Python, belum di Colab)
- ☐ `data/raw/` tidak ikut diunggah ke repositori
- ☐ `python cek_m2.py` berjalan tanpa status GAGAL (skrip belum ada di folder ini)