M2: Data Quality Report

Exploratory Data Analysis (KMTI21133), bobot 10%, dikumpulkan pada pertemuan 5.

Nama tim	Ngoding Jago
Anggota dan peran	1. Ugroseno Dwi Prakastyo (Developer) 2. Ridho Addin 3. Muhamad Rayhan Maulana
Judul proyek	Toko Ritel
Pertanyaan payung	Bagaimana performa penjualan bisnis secara menyeluruh dan pola perilaku belanja pelanggan di berbagai negara selama periode transaksi?
Dataset	Sales Transaction v.4a (Sales_Transaction_v_4a.csv)
Tautan repositori	https://github.com/azel2047/EDA2026/tree/main/notebooks/P05
Tanggal laporan	19 Oktober 2026

1. Ringkasan

Data ini layak dianalisis untuk penjualan per produk dan per negara, dengan tiga syarat: faktur pembatalan dipisahkan dari penjualan, pendapatan bulan November dan Desember 2019 tidak dibandingkan langsung dengan bulan sebelumnya, dan analisis per pelanggan mengecualikan 55 baris tanpa ID. Dataset berisi 536.350 baris transaksi ritel (23.204 faktur, 3.768 produk, 4.738 pelanggan, 38 negara) dari 1 Desember 2018 sampai 9 Desember 2019, dan 90% barisnya berasal dari United Kingdom. Tiga masalah terbesar adalah pergeseran harga mulai 23 November 2019, 8.585 baris Quantity negatif yang ternyata faktur pembatalan, dan 5.200 baris duplikat persis. Pergeseran harga paling berpengaruh: median harga harian runtuh dari sekitar 12 menjadi 6,19 pada satu tanggal dan menetap sampai akhir data, sehingga 48.872 baris (9,2%) ditandai, bukan dikoreksi. Keputusan lain yang berpengaruh adalah mempertahankan dan menandai faktur pembatalan, karena membuangnya menghilangkan retur senilai 4,2% dari penjualan bruto. Setelah membuang 5.200 duplikat, data bersih berisi

531.150 baris dan 20 kolom, dengan 498 sel kosong pada kolom asli.

2. Data dan cara memeriksanya

2.1 Asal data

Butir	Isi
Nama sumber	Sales Transaction v.4a (berkas Sales_Transaction_v_4a.csv)
Tautan atau instansi	https://www.kaggle.com/datasets/gabrielramos87/an-online-shop-business
Tanggal pengambilan	28 September 2026
Lisensi atau nomor izin	Bebas digunakan
Kalimat sitasi	Ramos, G. (2022). E-commerce Business Transaction: Sales Transaction v.4a.csv [Data set]. Kaggle. https://www.kaggle.com/datasets/gabrielramos87/an-online-shop-business

Butir provenans belum tercatat di folder kerja, jadi tidak diisi dari dugaan.

2.2 Ukuran dan cakupan

Data mentah berukuran 536.350 baris dan 8 kolom: TransactionNo, Date, ProductNo, ProductName, Price, Quantity, CustomerNo, Country. Satu baris mewakili satu produk pada satu faktur, sehingga kunci barisnya adalah pasangan TransactionNo dan ProductNo, bukan TransactionNo saja. Rentang waktunya 1 Desember 2018 sampai 9 Desember 2019 (13 bulan, dengan Desember 2019 baru terisi sampai tanggal 9). Data hanya menyimpan tanggal tanpa jam, dan mata uang Price tidak dinyatakan.

2.3 Cara pemeriksaan

Pemeriksaan dijalankan dengan pandas di Python (notebook P05_Workbook_Kelompok). Yang diperiksa: tipe data tiap kolom, spasi tersembunyi, placeholder teks dan angka sentinel, nilai unik dan varian penulisan, duplikat persis dan duplikat menurut kunci, kecocokan tanda

Quantity dengan awalan nomor faktur, rentang harga, harga tiap baris terhadap median produknya, median harga harian, dan pola kekosongan CustomerNo terhadap jenis faktur. Yang belum bisa dilakukan: validasi terhadap sumber asli (tidak tersedia), pembuktian MCAR atau MNAR (butuh pengetahuan tentang cara data dikumpulkan), dan perhitungan k pada data olahan.

3. Temuan kualitas data

Dimensi	Kolom	Masalah	Jumlah	Keparahan	Keputusan
Akurasi	Price	Median harga harian runtuh dari sekitar 12,25 menjadi 6,19 mulai 23 November 2019 dan menumpuk di 6,19	48.872 baris sesudah tanggal itu (9,2%); 37.118 baris bernilai tepat 6,19	Tinggi	Ditandai (harga_periode_turun), tidak dikoreksi
Validitas	Quantity	Nilai negatif, seluruhnya faktur berawalan C (pembatalan atau retur)	8.585 mentah, 8.548 bersih	Sedang	Ditandai (is_pembatalan), dipertahankan
Keunikan	Seluruh kolom	Baris identik penuh	5.200 (0,97%)	Sedang	Dibuang, satu disimpan
Keunikan	TransactionNo + ProductNo	Pasangan faktur dan produk berulang dengan Quantity atau Price berbeda	11.336 baris (5.207 kelompok beda Quantity, 1.033 beda Price)	Rendah	Ditandai (kunci_berulang), tidak dibuang
Validitas	Quantity	Nilai ekstrem: 80.995,	5 baris	Sedang	Ditandai (qty_ekstrem),

Dimensi	Kolom	Masalah	Jumlah	Keparahan	Keputusan
		74.215, 12.540 unit, dan dua pembatalannya			ditangani di pertemuan 6
Akurasi	Price	Harga lebih dari 3 kali atau kurang dari sepertiga median produk; 2.117 dari 2.127 baris jatuh pada November dan Desember 2019	2.127 baris	Sedang	Ditandai (harga_menyimpang)
Kelengkapan	CustomerNo	Kosong, 54 dari 55 baris di faktur pembatalan	55 (0,01%)	Rendah	Dibiarkan, ditandai (ada_pelanggan)
Kelengkapan	Country	Placeholder "Unspecified"	447 mentah, 443 bersih	Rendah	Diubah menjadi kosong
Konsistensi	Country	Nama tidak baku (EIRE, RSA); "European Community" bukan negara	8.105 baris; 58 baris	Rendah	EIRE menjadi Ireland, RSA menjadi South Africa; European Community dibiarkan
Validitas	Date	Disimpan sebagai teks format M/D/YYYY tanpa jam	536.350	Rendah	Dikonversi ke datetime

Dimensi	Kolom	Masalah	Jumlah	Keparahan	Keputusan
Konsistensi	CustomerNo	Terbaca float (17490.0) padahal ID	536.295	Rendah	Diubah menjadi ID teks

3.1 Pola nilai kosong

Tidak ada kolom dengan nilai kosong di atas 5%. Kedua kolom yang memiliki nilai kosong tetap dinyatakan polanya.

Kolom	Persen kosong	Dugaan	Dasar dugaan
CustomerNo	0,01% (55 dari 531.150)	MAR	54 dari 55 baris kosong berasal dari faktur pembatalan, padahal pembatalan hanya 1,6% data. Kekosongan bergantung pada jenis faktur, dan hal ini dapat dibuktikan dari data.
Country	0,08% (443 dari 531.150)	MAR	Hanya 7 pelanggan yang memiliki baris kosong, dan 218 dari 443 baris jatuh pada Juli 2019. Kosongnya mengelompok pada pelanggan tertentu, bukan acak.

4. Keputusan pembersihan dan alasannya

Keputusan 1: faktur pembatalan ditandai, bukan dikosongkan atau dibuang

Masalah	8.585 baris Quantity negatif pada data mentah (8.548 setelah duplikat dibuang)
Dugaan pola	Bukan nilai kosong. Tanda negatif cocok 100%

	dengan awalan C pada nomor faktur, tanpa satu pun pengecualian.
Keputusan	Dipertahankan dan ditandai dengan kolom is_pembatalan.
Alasan	Penyebabnya diketahui, yaitu retur atau pembatalan faktur, jadi ini bukan salah input. Barisnya membawa informasi produk, negara, dan tanggal yang masih berguna.
Alternatif ditolak	Dikosongkan ditolak karena penjualan neto menjadi salah dan informasi hilang. Dibalik menjadi positif ditolak karena menggandakan penjualan. Dibuang ditolak karena retur senilai 4,2% dari penjualan bruto ikut hilang.
Dampak	Tidak ada baris yang hilang. Penjualan bruto 62,78 juta, retur -2,66 juta, neto 60,12 juta. Rata-rata Quantity 9,989 pada seluruh baris dan 10,667 pada penjualan saja.

Keputusan 2: pergeseran harga ditandai, tidak dikoreksi

Masalah	Median harga harian turun dari sekitar 12,25 menjadi 6,19 mulai 23 November 2019 dan tidak kembali. Setelah tanggal itu harga maksimum hanya 44,37 dan 58% baris penjualan bernilai tepat 6,19. Untuk produk yang sama, median harga sesudah tanggal itu kira-kira separuh dari sebelumnya.
Dugaan pola	Pergeseran struktural, bukan salah input per baris. Sebabnya tidak diketahui: diskon besar, perubahan sistem harga, atau data yang diubah sebelum dibagikan.
Keputusan	Ditandai dengan kolom harga_periode_turun (48.872 baris), harga tidak diubah.
Alasan	Tidak ada informasi yang menunjukkan harga

	mana yang benar. Mengoreksi berarti menebak dan akan mengubah pendapatan dua bulan terakhir berdasarkan dugaan.
Alternatif ditolak	Menggandakan harga agar kembali ke tingkat sebelumnya ditolak karena itu mengarang nilai. Membuang baris sesudah 23 November ditolak karena menghapus 9,2% data, termasuk November yang merupakan bulan dengan baris terbanyak (82.821). Mengganti dengan median harga produk sebelum tanggal itu ditolak karena asumsinya sama tak berdasar.
Dampak	Tidak ada baris yang hilang. Median Price bulanan berkisar 11,53 sampai 12,82 dari Desember 2018 sampai November 2019, lalu 6,19 pada Desember 2019. Pendapatan November dan Desember 2019 tidak sebanding dengan bulan lain, dan batasan ini disebutkan di Bagian 6.

Keputusan 3: 5.200 duplikat persis dibuang

Masalah	5.200 baris (0,97%) identik pada seluruh delapan kolom.
Dugaan pola	Bukan nilai kosong. Dugaan: ganda input atau ekspor ganda. Dugaan ini tidak dapat dibuktikan dari data.
Keputusan	Satu baris disimpan, sisanya dibuang.
Alasan	Seluruh kolom sama persis, termasuk Quantity dan CustomerNo, sehingga pola ini lebih mirip ganda input daripada dua transaksi terpisah.
Alternatif ditolak	Dibiarkan ditolak karena menggandakan nilai transaksi sebesar 163.265,87. Risiko keputusan ini: bila dua scan barang yang sama di faktur yang sama memang sah, penjualan sedikit terlalu kecil.
Dampak	Rata-rata Price bergeser dari 12,662 menjadi

	12,670 (+0,07%), rata-rata Quantity dari 9,919 menjadi 9,989 (+0,71%). Nilai total mentah 60.280.024 turun menjadi 60.116.758 (-0,27%).

Keputusan 4: pasangan faktur dan produk yang berulang tidak dibuang

Masalah	TransactionNo bukan kunci baris. Setelah duplikat persis dibuang, 11.336 baris berbagi pasangan (TransactionNo, ProductNo) dengan baris lain.
Dugaan pola	Bukan nilai kosong. Quantity berbeda pada 5.207 kelompok dan Price berbeda pada 1.033 kelompok, jadi ini kemungkinan scan ulang barang yang sama.
Keputusan	Ditandai dengan kolom kunci_berulang, semua baris dipertahankan.
Alasan	Barisnya bukan duplikat: nilainya berbeda, dan setiap baris membawa penjualan yang mungkin sah.
Alternatif ditolak	Menerapkan aturan drop_duplicates menurut nomor faktur ditolak karena menghapus hampir seluruh data (satu faktur memuat banyak produk). Menyimpan satu baris per pasangan ditolak karena membuang 5.783 baris penjualan. Menjumlahkan Quantity ditolak karena harga di 1.033 kelompok berbeda.
Dampak	Tidak ada baris yang hilang. Jumlah baris tidak sama dengan jumlah produk unik per faktur, jadi agregasi per produk harus menjumlah Quantity.

Keputusan 5: CustomerNo kosong tidak diimputasi

Masalah	CustomerNo kosong pada 55 baris.
Dugaan pola	MAR. 54 dari 55 baris berasal dari faktur pembatalan yang hanya 1,6% dari data.

Keputusan	Dibiarkan kosong dan ditambahkan kolom penanda ada_pelanggan.
Alasan	ID pelanggan adalah identitas, bukan besaran, sehingga tidak ada nilai tengah yang bermakna. Pengisian apa pun berarti mengatribusikan transaksi ke orang yang tidak kita kenal.
Alternatif ditolak	Diisi dengan modus ditolak: pelanggan paling aktif (17841) bertambah dari 7.803 menjadi 7.858 baris dan jumlah retur atas namanya palsu. Membuang 55 baris ditolak karena 54 di antaranya retur, sehingga retur terhitung terlalu kecil.
Dampak	Tidak ada baris yang hilang. Analisis per pelanggan dibatasi pada 531.095 baris yang punya ID, dan batasan ini disebutkan di Bagian 6.

5. Dampak pembersihan terhadap data

5.1 Sebelum dan sesudah

Ukuran	Sebelum	Sesudah	Catatan
Jumlah baris	536.350	531.150	5.200 duplikat persis dibuang
Jumlah kolom	8	20	12 kolom penanda dan turunan ditambahkan, kolom asli tidak berubah nama
Total sel kosong (8 kolom asli)	55	498	Bertambah 443 karena "Unspecified" pada Country kini jujur mengaku kosong. CustomerNo tetap 55
Baris duplikat	5.200	0	
Jumlah kategori pada	38	37	"Unspecified" menjadi

Ukuran	Sebelum	Sesudah	Catatan
kolom kunci (Country)			kosong; EIRE dan RSA hanya berganti nama
Nilai unik pada kolom identitas	CustomerNo 4.738; ProductNo 3.768; TransactionNo 23.204	Sama	Duplikat yang dibuang berada di dalam faktur yang sama

5.2 Dampak terhadap sebaran

Kolom	Mean sebelum	Mean sesudah	Pergeseran	Penilaian
Price (membuang duplikat)	12,662	12,670	+0,07%	Dapat diabaikan. Median tetap 11,94, standar deviasi 8,490 menjadi 8,526.
Quantity (membuang duplikat)	9,919	9,989	+0,71%	Kecil. Median tetap 3. Standar deviasi 216,66 menjadi 217,70 dan hampir seluruhnya berasal dari lima baris ekstrem; tanpa baris itu standar deviasi 40,7.
Quantity (memisahkan retur)	9,989 (semua baris)	10,667 (penjualan saja)	+6,79%	Pemisahan retur menggeser rata-rata cukup jauh. Median naik dari 3 menjadi 4. Karena itu retur tidak dibuang diam-diam, tetapi ditandai agar analisis dapat

Kolom	Mean sebelum	Mean sesudah	Pergeseran	Penilaian
				memilih.
Price (memisahkan periode setelah 23 November)	12,637 (penjualan, semua periode)	Median 12,25 sebelum dan 6,19 sesudah	-49%	Pergeseran harga paling besar pada data ini. Keputusan menandai, bukan mengoreksi, tidak mengubah sebaran, jadi sebaran harga di akhir periode harus dibaca terpisah.

Median Price per bulan: Desember 2018 12,82; Januari sampai Maret 2019 12,40; April 12,25; Mei 12,38; Juni 12,25; Juli dan Agustus 11,94; September 12,15; Oktober 12,25; November 11,53; Desember 2019 6,19.

6. Keterbatasan

- Harga setelah 23 November 2019 tidak dapat dipulihkan. Pertanyaan yang terdampak: tren pendapatan bulanan, produk terlaris pada dua bulan terakhir, dan perbandingan Desember 2019 dengan Desember 2018. Arah kesalahannya tidak diketahui: bila penurunan harga adalah kesalahan data, pendapatan terlalu kecil; bila diskon nyata, angkanya benar tetapi tidak sebanding dengan bulan lain.
- 55 baris tanpa CustomerNo tidak dapat dikaitkan dengan pelanggan, dan hampir seluruhnya retur. Analisis per pelanggan akan sedikit menghitung retur terlalu kecil.
- Tidak ada dugaan MNAR yang perlu dibuktikan karena kolom bernilai kosong sangat sedikit (di bawah 0,1%). Dugaan MAR pada CustomerNo dan Country didasarkan pada pola dalam data, bukan pada pengetahuan tentang cara data dikumpulkan.
- Pemeriksaan yang belum dilakukan: validasi terhadap sumber asli, penentuan mata uang Price, perhitungan nilai k pada data olahan, dan pengujian notebook dengan Restart and run all di Colab (sudah diuji di lingkungan Python lokal).
- Asumsi yang perlu dikonfirmasi ke pemilik data: baris identik penuh adalah ganda input;

awalan C berarti pembatalan; EIRE sama dengan Ireland; "Unspecified" dan "European Community" tidak memiliki arti khusus; Desember 2019 terhenti pada tanggal 9 karena pengambilan data, bukan karena transaksi berhenti.

7. Penanganan data pribadi

Butir	Keterangan
Kolom data pribadi pada data olahan	CustomerNo, ID pelanggan. Tidak ada kolom nama, alamat, atau kontak.
Tindakan penanganan yang diterapkan	CustomerNo tidak diubah dan tidak diimputasi, hanya dijadikan teks. Tidak ada kolom pribadi yang ditambahkan selama pembersihan.
Nilai k pada data yang diunggah	Belum dihitung. Isi mengikuti metode pertemuan 3.
Status repositori (publik atau privat)	(isi status repositori)
data/raw/ masuk .gitignore	(isi setelah diperiksa)

8. Langkah berikutnya

- Tanyakan kepada dosen atau pemilik data penyebab pergeseran harga pada 23 November 2019.
- Untuk M3 (notebook EDA tahap 1, pertemuan 8): analisis univariat Price dan Quantity, dan keputusan tentang lima baris Quantity ekstrem.
- Jalankan analisis bulanan dua kali, dengan dan tanpa baris bertanda harga_periode_turun, lalu bandingkan kesimpulannya.
- Jalankan Restart and run all di Colab dan cek_m2.py, lalu lengkapi data tim, provenans, dan nilai k.

Lampiran A: Cleaning log

Ringkasan 16 langkah yang dicatat otomatis oleh notebook. Versi lengkap beserta kolom keputusan ada di berkas cleaning_log.md.

#	Langkah	Baris terdampak	Alasan
1	CustomerNo dari float menjadi ID teks	536.295	ID bukan besaran yang dihitung; float menampilkan ".0"
2	Konversi Date ke datetime (M/D/YYYY)	536.350	Bulan di depan; dayfirst akan menukar bulan dan hari
3	Buang spasi awal dan akhir kolom teks	0	Spasi tersembunyi memecah groupby; tidak ditemukan
4	Placeholder teks menjadi kosong	447	"Unspecified" pada Country bukan nama negara
5	Placeholder numerik pada Price dan Quantity menjadi kosong	0	Sudah diperiksa, tidak ada sentinel
6	Seragamkan nama negara (EIRE, RSA)	8.105	Nama baku lewat peta eksplisit
7	Hapus duplikat persis	5.200	Seluruh kolom identik; satu baris disimpan
8	Tandai (faktur, produk) berulang	11.336	Quantity dan sebagian Price berbeda; bukan duplikat input
9	Buang baris tanpa TransactionNo atau ProductNo	0	Kunci kosong tidak dapat ditelusuri; kunci lengkap
10	Tandai faktur pembatalan (is_pembatalan)	8.548	Quantity negatif cocok 100% dengan awalan C; retur sah
11	Price kurang dari atau sama dengan 0 menjadi kosong	0	Mustahil; tidak ditemukan

#	Langkah	Baris terdampak	Alasan
12	Tandai harga menyimpang	2.127	Lebih dari 3 kali atau kurang dari sepertiga median produk; penyebab tidak diketahui
13	Tandai Quantity ekstrem	5	Nilai mutlak di atas 10.000; menunggu pertemuan 6
14	Tandai periode setelah pergeseran harga	48.872	Median harga runtuh mulai 2019-11-23; sebab tidak diketahui
15	CustomerNo dibiarkan kosong, diberi penanda	55	Kosong tidak acak; ID tidak bisa diimputasi
16	Country kosong dibiarkan	443	Tidak ada kolom lain yang menentukan negara

Lampiran B: Peta keputusan manual

Nilai asal	Diubah menjadi	Dasar keputusan
EIRE	Ireland	Nama lokal untuk Irlandia; tidak ada "Ireland" lain di data; perlu dikonfirmasi ke pemilik data
RSA	South Africa	Singkatan Republic of South Africa
Unspecified	(kosong)	Penanda "tidak diketahui", bukan nama negara
Faktur berawalan C	is_pembatalan = True	Cocok 100% dengan Quantity negatif pada 8.548 baris, tanpa pengecualian
European Community	Tidak diubah	Bukan negara tunggal; tidak ada

Nilai asal	Diubah menjadi	Dasar keputusan
		dasar untuk menebak negaranya (58 baris)